



Conceptos Transfer Learning-FineTuning



Transfer Learning

Técnica la que se toma un modelo desarrollado para una tarea específica y se reutiliza como punto de partida para una tarea relacionada pero diferente.

Transfer Learning


Técnica la que se toma un modelo desarrollado para una tarea específica y se reutiliza como punto de partida para una tarea relacionada pero diferente.

Esta técnica aprovecha el conocimiento previo (pesos, características aprendidas, etc.) adquirido por el modelo durante su entrenamiento inicial para facilitar o mejorar el aprendizaje en una nueva tarea

Transfer Learning

Técnica la que se toma un modelo desarrollado para una tarea específica y se reutiliza como punto de partida para una tarea relacionada pero diferente.

Esta técnica aprovecha el conocimiento previo (pesos, características aprendidas, etc.) adquirido por el modelo durante su entrenamiento inicial para facilitar o mejorar el aprendizaje en una nueva tarea

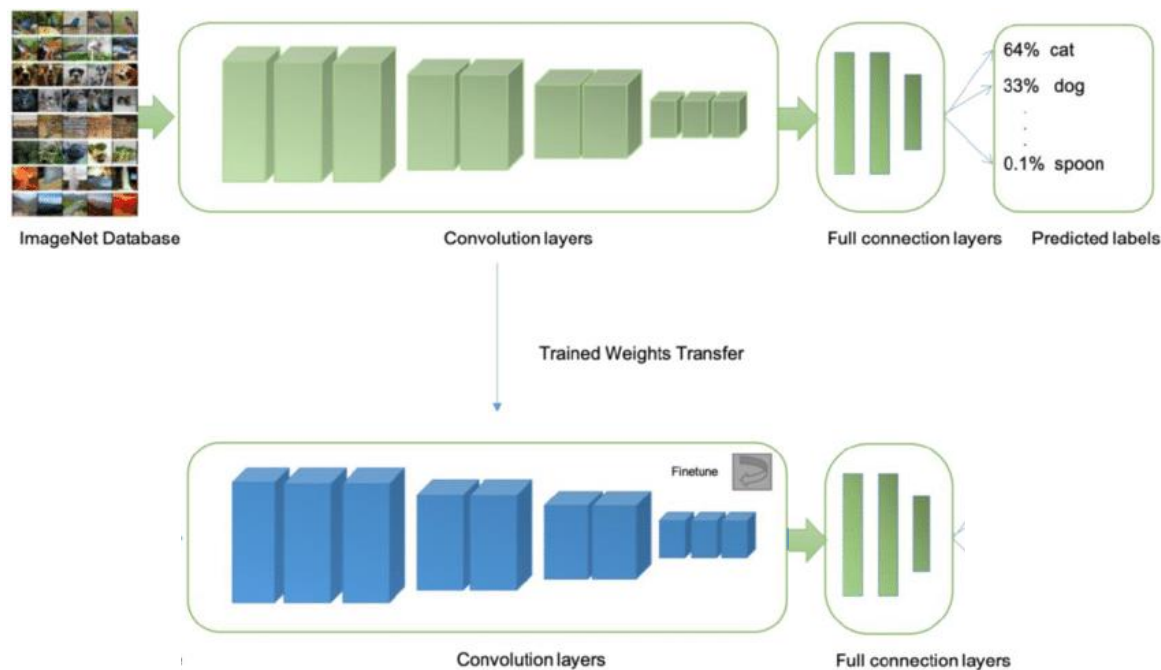


1. SELECCIÓN DEL MODELO DE REFERENCIA

Transfer Learning

Técnica la que se toma un modelo desarrollado para una tarea específica y se reutiliza como punto de partida para una tarea relacionada pero diferente.

Esta técnica aprovecha el conocimiento previo (pesos, características aprendidas, etc.) adquirido por el modelo durante su entrenamiento inicial para facilitar o mejorar el aprendizaje en una nueva tarea




1. SELECCIÓN DEL MODELO DE REFERENCIA

2. “DESCARGA” DEL MODELO

Transfer Learning

Técnica la que se toma un modelo desarrollado para una tarea específica y se reutiliza como punto de partida para una tarea relacionada pero diferente.

Esta técnica aprovecha el conocimiento previo (pesos, características aprendidas, etc.) adquirido por el modelo durante su entrenamiento inicial para facilitar o mejorar el aprendizaje en una nueva tarea

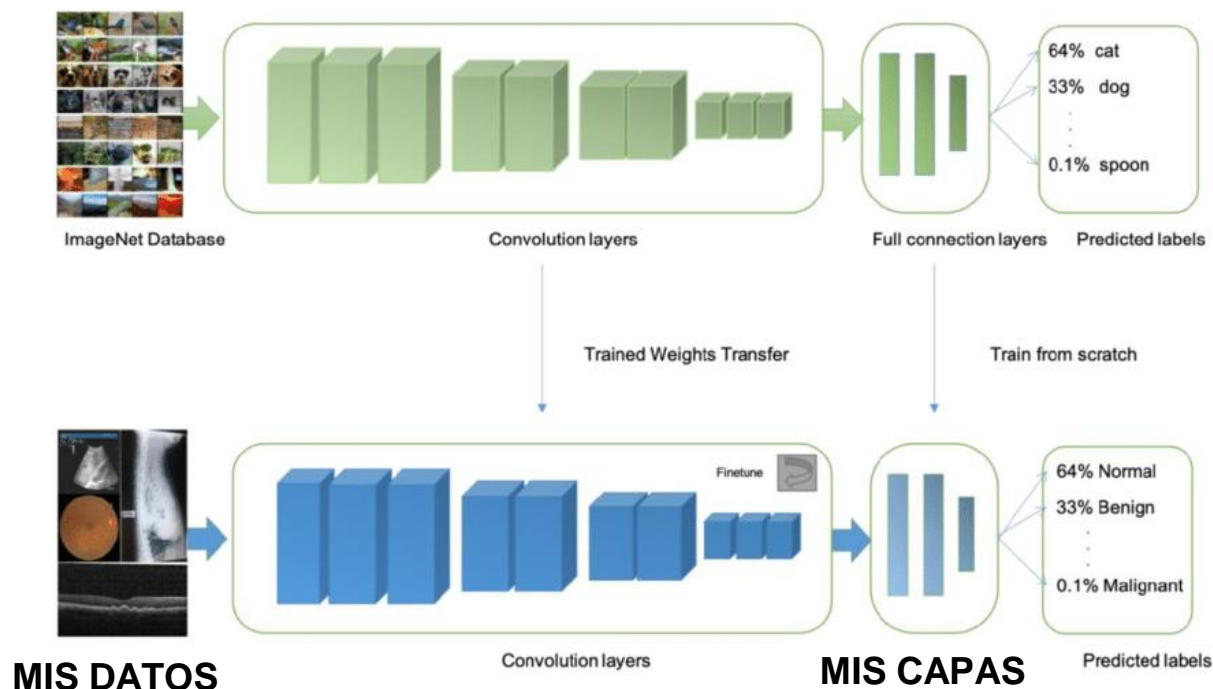


1. SELECCIÓN DEL MODELO DE REFERENCIA
2. “DESCARGA” DEL MODELO
3. SUSTITUCION DE LA CABEZA

Transfer Learning

Técnica la que se toma un modelo desarrollado para una tarea específica y se reutiliza como punto de partida para una tarea relacionada pero diferente.

Esta técnica aprovecha el conocimiento previo (pesos, características aprendidas, etc.) adquirido por el modelo durante su entrenamiento inicial para facilitar o mejorar el aprendizaje en una nueva tarea



1. SELECCIÓN DEL MODELO DE REFERENCIA

2. “DESCARGA” DEL MODELO

3. SUSTITUCION DE LA CABEZA

4. ENTRENAMIENTO CON NUESTROS DATOS:

- Sin tocar el modelo de referencia
- **Fine Tuning:** Reentrenando algunos de los pesos de referencia

Fine Tuning vs Transfer Learning

El fine-tuning implica reentrenar todas o parte de las capas del modelo de referencia preentrenado. Se puede considerar un caso especial de Transfer Learning.

Fine Tuning vs Transfer Learning

El fine-tuning implica reentrenar todas o parte de las capas del modelo de referencia preentrenado. Se puede considerar un caso especial de Transfer Learning.

Característica	Transfer Learning	Fine-Tuning
Definición	Usar un modelo preentrenado en una tarea como punto de partida para otra tarea relacionada.	Ajustar o "afinar" las capas de un modelo preentrenado específicamente para mejorar el rendimiento en una tarea relacionada.
Objetivo	Aprovechar el conocimiento adquirido por el modelo en una tarea previa para facilitar el aprendizaje en una nueva tarea.	Mejorar la precisión y el rendimiento del modelo en la nueva tarea ajustando sus parámetros.
Datos de Entrenamiento	Puede requerir menos datos de entrenamiento para la nueva tarea debido al conocimiento transferido.	Requiere datos de entrenamiento específicos de la nueva tarea para el ajuste fino de las capas.
Rapidez	El proceso puede ser relativamente rápido, ya que menos capas son ajustadas o reentrenadas.	Puede ser más lento que el transfer learning puro, ya que implica ajustes más extensos al modelo.
Aplicaciones	Útil cuando la nueva tarea es similar pero no idéntica a la tarea original.	Beneficioso cuando se necesita alta precisión y el modelo debe ajustarse específicamente a los detalles de la nueva tarea.

Fine Tuning vs Transfer Learning

El fine-tuning implica reentrenar todas o parte de las capas del modelo de referencia preentrenado. Se puede considerar un caso especial de Transfer Learning.

Característica	Transfer Learning	Fine-Tuning
Definición	Usar un modelo preentrenado en una tarea como punto de partida para otra tarea relacionada.	Ajustar o "afinar" las capas de un modelo preentrenado específicamente para mejorar el rendimiento en una tarea relacionada.
Objetivo	Aprovechar el conocimiento adquirido por el modelo en una tarea previa para facilitar el aprendizaje en una nueva tarea.	Mejorar la precisión y el rendimiento del modelo en la nueva tarea ajustando sus parámetros.
Datos de Entrenamiento	Puede requerir menos datos de entrenamiento para la nueva tarea debido al conocimiento transferido.	Requiere datos de entrenamiento específicos de la nueva tarea para el ajuste fino de las capas.
Rapidez	El proceso puede ser relativamente rápido, ya que menos capas son ajustadas o reentrenadas.	Puede ser más lento que el transfer learning puro, ya que implica ajustes más extensos al modelo.
Aplicaciones	Útil cuando la nueva tarea es similar pero no idéntica a la tarea original.	Beneficioso cuando se necesita alta precisión y el modelo debe ajustarse específicamente a los detalles de la nueva tarea.

- Transfer require menos datos nuestros, requiere menos tiempos de entrenamiento, etc
- Finetuning se ajusta mejor a nuestro problema y da en general mejores resultados

Fine Tuning vs Transfer Learning

El fine-tuning implica reentrenar todas o parte de las capas del modelo de referencia preentrenado. Se puede considerar un caso especial de Transfer Learning.

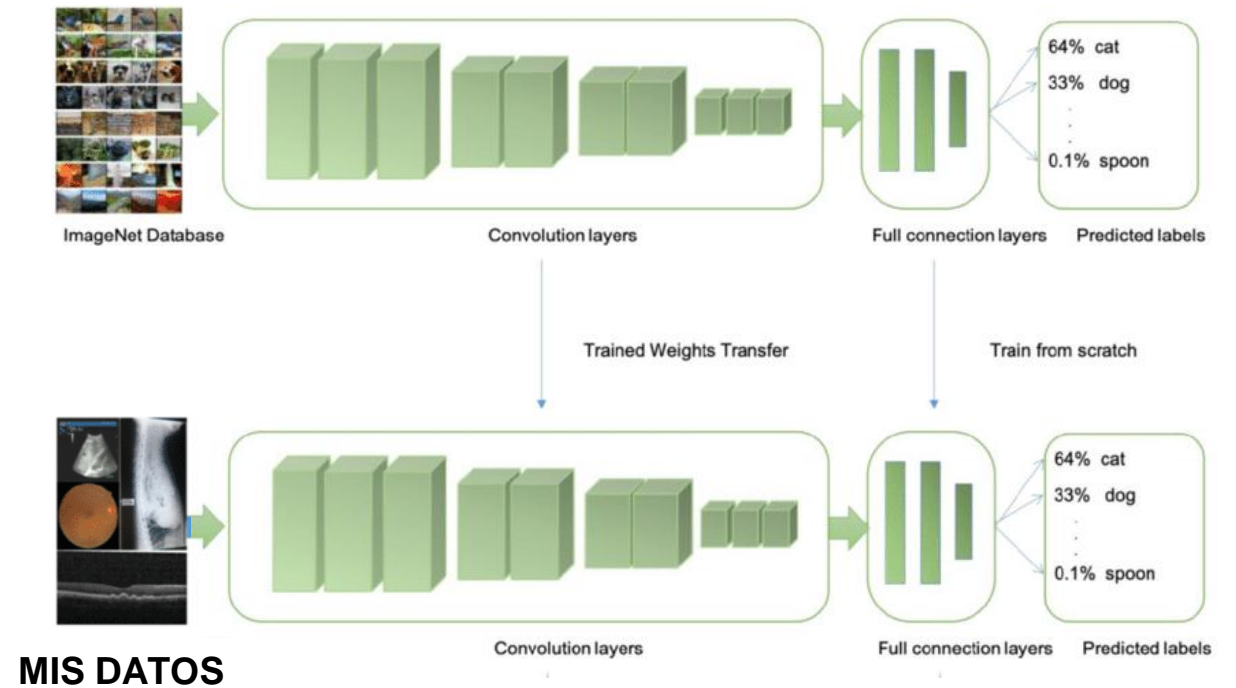
Característica	Transfer Learning	Fine-Tuning
Definición	Usar un modelo preentrenado en una tarea como punto de partida para otra tarea relacionada.	Ajustar o "afinar" las capas de un modelo preentrenado específicamente para mejorar el rendimiento en una tarea relacionada.
Objetivo	Aprovechar el conocimiento adquirido por el modelo en una tarea previa para facilitar el aprendizaje en una nueva tarea.	Mejorar la precisión y el rendimiento del modelo en la nueva tarea ajustando sus parámetros.
Datos de Entrenamiento	Puede requerir menos datos de entrenamiento para la nueva tarea debido al conocimiento transferido.	Requiere datos de entrenamiento específicos de la nueva tarea para el ajuste fino de las capas.
Rapidez	El proceso puede ser relativamente rápido, ya que menos capas son ajustadas o reentrenadas.	Puede ser más lento que el transfer learning puro, ya que implica ajustes más extensos al modelo.
Aplicaciones	Útil cuando la nueva tarea es similar pero no idéntica a la tarea original.	Beneficioso cuando se necesita alta precisión y el modelo debe ajustarse específicamente a los detalles de la nueva tarea.

- Transfer requires less of our data, requires less training times, etc
- Finetuning adapts better to our problem and generally gives better results

Aproximación mixta: Transfer learning inicial con menos datos, utilizar el modelo adaptado e ir acumulando datos hasta poder hacer un buen fine-tuning a nuestro dataset ampliado.

Zero-shot Learners/learning

Zero-shot Learners/learning




Zero-shot Learners/learning

•**Reconocimiento de Objetos:** Identificar objetos en imágenes que no estaban presentes en el conjunto de datos de entrenamiento.

•**Procesamiento de Lenguaje Natural (NLP):** Comprender o generar texto sobre temas o conceptos que no se vieron durante el entrenamiento.

•**Clasificación de Texto:** Categorizar textos en temas o categorías sin ejemplos previos.



Ventajas y desafíos del Transfer Learning

Ventajas y desafíos del Transfer Learning



- Eficiencia en Tiempo y Datos
- Mejora del Rendimiento
- Versatilidad

Ventajas y desafíos del Transfer Learning



- Eficiencia en Tiempo y Datos
- Mejora del Rendimiento
- Versatilidad




- Sobreajuste
- Transferencia Negativa
- Selección del Modelo
- Proceso difícil de ajustar

Ventajas y desafíos del Transfer Learning



- Eficiencia en Tiempo y Datos
- Mejora del Rendimiento
- Versatilidad



- Sobreajuste
- Transferencia Negativa
- Selección del Modelo
- Proceso difícil de ajustar

